



# Administration système

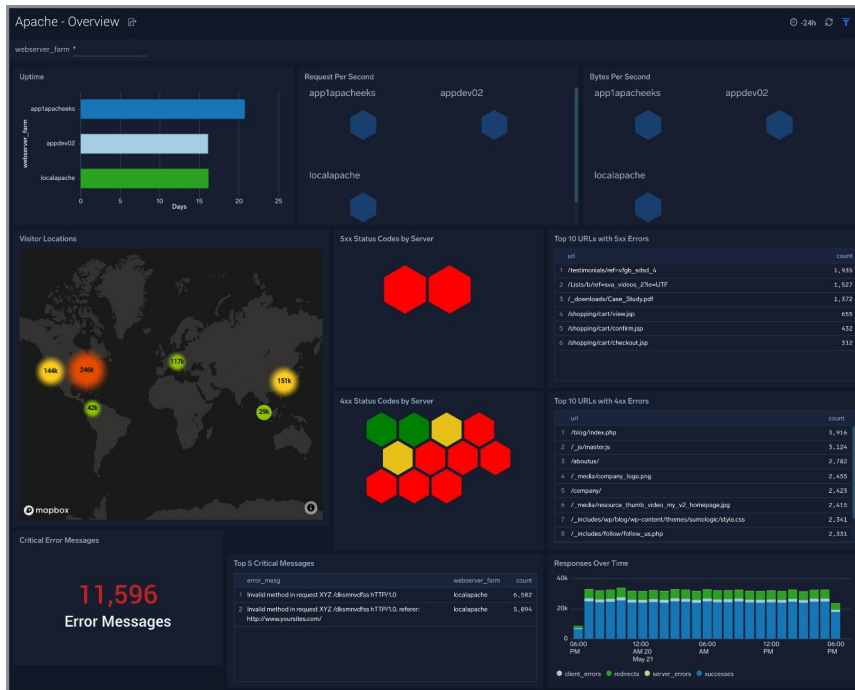
Travaux dirigés

Extraction et traitement de  
données d'un fichier de log  
Apache



# Outils de reporting Apache

- Le contexte
  - Il existe des outils de reporting payants mais votre boss préfère vous demander d'en fabriquer un moins conséquent que celui-ci mais...
    - Gratuit et
    - 'Adapté au contexte de votre entreprise'



<https://www.sumologic.com/application/apache/>



# Outils de reporting Apache

- Le besoin
  - Votre boss voudrait un script Python qui lui permette de connaître les connexions au serveur Apache avec les données suivantes :
    - l'adresse IP
    - le status de la réponse
    - le nombre d'octets envoyés
    - Tout cela regroupé par @IP



# Résultat

- Quel est le résultat attendu ?

```
# affichage de chaque ligne du fichier
```

```
{'remote_host': '127.0.0.1', 'status': '200', 'bytes_sent': '2326'}
```

```
{'remote_host': '192.168.0.1', 'status': '200', 'bytes_sent': '4567'}
```

```
{'remote_host': '111.222.333.123', 'status': '200', 'bytes_sent': '198'}
```

```
{'remote_host': '111.222.333.123', 'status': '200', 'bytes_sent': '28083'}
```

```
{'remote_host': '111.222.333.123', 'status': '200', 'bytes_sent': '9332'}
```

```
{'remote_host': '111.222.333.123', 'status': '200', 'bytes_sent': '207'}
```

```
# traitement pour regroupement par @IP
```

```
{'127.0.0.1': [2326], '192.168.0.1': [4567], '111.222.333.123': [198, 28083, 9332, 207]}
```



# Soit le fichier de log suivant :

## acces1.log (au format Combined Log Format)

```
127.0.0.0.001 - frank [10/Oct/2000:13:55:36 -0700] "GET /apache_pb.gif HTTP/1.0" 200 2326 "http://www.example.com/start.html" "Mozilla/4.08 [en] (Win98; I ;Nav)"
192.168.0.001 - Joe [10/Oct/2000:13:55:36 -0700] "GET /apache_pb.gif HTTP/1.0" 200 4567 "http://www.example.com/start.html" "Mozilla/4.08 [en] (Win98; I ;Nav)"
111.222.333.123 HOME - [01/Feb/1998:01:08:39 -0800] "GET /bannerad/ad.htm HTTP/1.0" 200 198 "http://www.referrer.com/bannerad/ba_intro.htm" "Mozilla/4.01 (Macintosh; I; PPC)"
111.222.333.123 HOME - [01/Feb/1998:01:08:46 -0800] "GET /bannerad/ad.htm HTTP/1.0" 200 28083 "http://www.referrer.com/bannerad/ba_intro.htm" "Mozilla/4.01 (Macintosh; I; PPC)"
111.222.333.123 AWAY - [01/Feb/1998:01:08:53 -0800] "GET /bannerad/ad7.gif HTTP/1.0" 200 9332 "http://www.referrer.com/bannerad/ba_ad.htm" "Mozilla/4.01 (Macintosh; I; PPC)"
111.222.333.123 AWAY - [01/Feb/1998:01:09:14 -0800] "GET /bannerad/click.htm HTTP/1.0" 200 207 "http://www.referrer.com/bannerad/menu.htm" "Mozilla/4.01 (Macintosh; I; PPC)"
```

```
127.0.0.1 - frank [10/Oct/2000:13:55:36 -0700] "GET /apache_pb.gif HTTP/1.0" 200 2326 "http://www.example.com/start.html" "Mozilla/4.08 [en] (Win98; I ;Nav)"
192.168.0.1 - Joe [10/Oct/2000:13:55:36 -0700] "GET /apache_pb.gif HTTP/1.0" 200 4567 "http://www.example.com/start.html" "Mozilla/4.08 [en] (Win98; I ;Nav)"
111.222.333.123 HOME - [01/Feb/1998:01:08:39 -0800] "GET /bannerad/ad.htm HTTP/1.0" 200 198 "http://www.referrer.com/bannerad/ba_intro.htm" "Mozilla/4.01 (Macintosh; I; PPC)"
111.222.333.123 HOME - [01/Feb/1998:01:08:46 -0800] "GET /bannerad/ad.htm HTTP/1.0" 200 28083 "http://www.referrer.com/bannerad/ba_intro.htm" "Mozilla/4.01 (Macintosh; I; PPC)"
111.222.333.123 AWAY - [01/Feb/1998:01:08:53 -0800] "GET /bannerad/ad7.gif HTTP/1.0" 200 9332 "http://www.referrer.com/bannerad/ba_ad.htm" "Mozilla/4.01 (Macintosh; I; PPC)"
111.222.333.123 AWAY - [01/Feb/1998:01:09:14 -0800] "GET /bannerad/click.htm HTTP/1.0" 200 207 "http://www.referrer.com/bannerad/menu.htm" "Mozilla/4.01 (Macintosh; I; PPC)"
```

0 1 2 3 4 5 5 7 8 9

```
127.0.0.1 - frank [10/Oct/2000:13:55:36 -0700] "GET /apache_pb.gif HTTP/1.0" 200 2326 "http://w
192.168.0.1 - Joe [10/Oct/2000:13:55:36 -0700] "GET /apache_pb.gif HTTP/1.0" 200 4567 "http://w
111.222.333.123 HOME - [01/Feb/1998:01:08:39 -0800] "GET /bannerad/ad.htm HTTP/1.0" 200 198 "ht
111.222.333.123 HOME - [01/Feb/1998:01:08:46 -0800] "GET /bannerad/ad.htm HTTP/1.0" 200 28083 "
111.222.333.123 AWAY - [01/Feb/1998:01:08:53 -0800] "GET /bannerad/ad7.gif HTTP/1.0" 200 9332 "
111.222.333.123 AWAY - [01/Feb/1998:01:09:14 -0800] "GET /bannerad/click.htm HTTP/1.0" 200 207
```

<https://httpd.apache.org/docs/2.4/logs.html#accesslog>



# Données significatives

- Les données qui nous intéressent sont :
  - 0 : l'adresse IP
  - 8 : le status de la réponse
  - 9 : le nombre d'octets envoyés
  - L'ensemble des octets regroupés par @IP

0	1	2	3	4	5	5	7	8	9	
127.0.0.1	-	frank	[10/Oct/2000:13:55:36	-0700]	"GET	/apache_pb.gif	HTTP/1.0"	200	2326	"http://w
192.168.0.1	-	Joe	[10/Oct/2000:13:55:36	-0700]	"GET	/apache_pb.gif	HTTP/1.0"	200	4567	"http://w
111.222.333.123	HOME	-	[01/Feb/1998:01:08:39	-0800]	"GET	/bannerad/ad.htm	HTTP/1.0"	200	198	"ht
111.222.333.123	HOME	-	[01/Feb/1998:01:08:46	-0800]	"GET	/bannerad/ad.htm	HTTP/1.0"	200	28083	"
111.222.333.123	AWAY	-	[01/Feb/1998:01:08:53	-0800]	"GET	/bannerad/ad7.gif	HTTP/1.0"	200	9332	"
111.222.333.123	AWAY	-	[01/Feb/1998:01:09:14	-0800]	"GET	/bannerad/click.htm	HTTP/1.0"	200	207	"



# Processus

- Quel est le processus de création d'un script Python qui va donner ce résultat ?
- Le script doit :
  - être appelé depuis la ligne de commande
  - Vérifier qu'au moins un argument a été passé
  - Prendre en argument le nom du fichier de log (`sys.argv`)
  - Vérifier que le fichier existe (exception)
  - Fonction 1 : parcourir toutes les lignes du fichier (boucle `for`)
    - Fonction 2 :
      - décomposer la ligne (`split`)
      - Créer un dictionnaire avec trois clés
      - Afficher ce dictionnaire
    - *Faire le regroupement par adresse IP (méthode `setdefault`)*